

# Formalni jezici i jezični procesori I

## 2020./2021.

Prof. dr. sc. Sanda Martinčić - Ipšić  
[smarti@inf.uniri.hr](mailto:smarti@inf.uniri.hr)

# Merlin pswd

- FJJP
- Predavanja počinju u 10:30

# Epidemiološke upute

1. Prije polaska kod kuće **mjerite temperaturu**. U slučaju temperature ili bilo kojeg simptoma ostajete kući.
  - nastava je ionako uvijek i online
2. Ulazite kroz glavna vrata u predavaonicu **s maskama**.
3. Uvijek (na svim predavanjima) **sjedite na istom mjestu**.
4. Maske tijekom predavanja možete skinuti, ali čim se dižete s mjesta masku je potrebno staviti
5. Nosite **sredstvo za dezinfekciju** sa sobom, klupe se čiste ali neće biti vremena da se čiste između predavanja

**MOLBA:** Pridržavajte se svih uputa da čim dulje izdržimo u predavaonici, kad uvjeti ne budu zadovoljeni prelazimo na online <sub>3</sub>

# Epidemiološke upute II

- Potpisuje se **epidemiološka evidencija** prisutnih studenata
  - Papir se potpisuje prilikom ulaza u predavaonicu, kod potpisivanja održavati razmak od 1.5 m
  - papir neće kružiti

# Dozvoljena mjesta

- Sjedi se isključivo na mjestima, koja su označena s naljepnicama
- **Obavezno je pravilno nošenje maski:**
  - U svim učionicama, kao i u svim zatvorenim prostorima
  - U cijeloj zgradi
  - Tijekom predavanja i vježbi

# Stream link za predavanja

- <https://www.twitch.tv/oiri028>
- Operativne stvari pitati u chat-u
  - (čujem, ne čujem, vidim, ne vidim)
- pitanja vezana uz sadržaj postaviti na forumu u Merlin-u
  - svi studenti mogu vidjeti pitanje i čak i odgovoriti
  - Za takvu aktivnost vas mogu nagraditi dodatnim bodovima

# ILI

- Teorijske osnove računarstva
  - Teorijski jezici
- 
- Theory of Computation
  - Automata Theory
  - Theoretical Languages

# Raspored

- predavanja srijeda 028 10:30-12:00
- vježbe srijeda 028 12:00-13:30
- konzultacije – po prethodnoj najavi e-mailom  
(srijedom nakon predavanja) smarti@uniri.hr
- asistent: Karlo Babić, : karlo.babic@uniri.hr

# Polaganje ispita

## jednopredmetni, matematika, fizika

- Prisutnost na nastavi: 80%
- Domaće zadaće:  $4 \times 5 = \mathbf{20}$  bodova
- 2 kolokvija: **50** bodova
- ili seminar 25 bodova
- Završni ispit: **30** bodova (minimalno 50%)
- rokovi za predaju DZ **nisu** promjenjivi odnosno ukoliko se ne preda u roku smatra se da zadaća/seminar/rad nije predan

# Polaganje ispita II

- UMJESTO 2. KOLOKVIJA:
- (rok za dogovor je do **16.12.**)

**OPCIJA: seminar - PROGRAMERSKI!!!**

- moguće prikupljanje dodatnih bodova
- nastavak rada na seminaru u sljedećem semestru te za Završni/Diplomski rad
- TEMA: Rad na prikupljanju podataka, pasiranjima formata, metode strojnog učenje, parseri, kompleksne mreže, teorija grafova,... ...
- ili po dogovoru ....

# Polaganje ispita -dvopredmetni

- Prisutnost na nastavi: 50%
- 2 Kolokvija: **50** bodova
- Završni ispit: **30** bodova (minimalno 50%)
- potrebno prikupiti 30 za popravni i 40 Završni
- **DODATNO NEMA Domaćih Zadaća!!!!**
- **ALI možete ih predati za dodatne bodove**
  - u tom slučaju kad prijeđete prag za završni ukupni broj bodova se zbraja i normira na 80 (dijeli s 80)
  - znači maksimalno je moguće postići 100/80
  - ocjenska ljestvica ostaje ista

# Završna ocjena

- A – 90% - 100% (ekvivalent: izvrstan 5)
- B – 75% - 89,9% (ekvivalent: vrlo dobar 4)
- C – 60% - 74,9% (ekvivalent: dobar 3)
- D – 50% - 59,9% (ekvivalent: dovoljan 2)
- F – 0% - 49,9% (ekvivalent: nedovoljan 1)

# Literatura

- S. Srbljić. Jezični procesori I, Element, Zagreb, 2002. ILI
- Srbljić Siniša: Uvod u teoriju računarstva. Element, Zagreb, 2007.
- M. Sipser, Introduction to the Theory of Computation, Brooks Cole, 1<sup>st</sup> edition, 1996.
- J. E. Hopcroft, J. D. Ullman. Introduction to Automata Theory, Languages and Computation, Addison-Wesley, 1979. (3rd edition 2006)

# Izvedbeni plan I

## DETALJNO U DINPU

21.10.2020. Rok za predaju 1. domaće zadaće

18.11.2020. Rok za predaju 2. domaće zadaće

**25.11.2020. 1. Kolokvij**

16.12.2020. Rok za predaju 3. domaće zadaće

**Božićni blagdani**

**20.01.2021. 2. Kolokvij**

20.01.2021. Rok za predaju 4. domaće zadaće

## Ispitni rokovi (U ISVU)

- 11.02.2021. u 10
- 25.02.2021. u 10
- 11.03.2021. u 10
- 09.09.2021. u 10

# Izvedbeni plan III

- **ROKOVI u DINPU:**
- uvijek provjeriti stanje u **ISVU**
- završni ispit: **4 roka**
- Prolaznost 78% (prošla ak. god.)

# Sadržaj

- Uvod
  - rad jezičnog procesora
- Automati:
  - DKA, NKA,  $\varepsilon$  - NKA, Mooreov i Mealyev automat
- Regularni izrazi
- Gramatike
- Parseri
- Potisni automat
- Turingov stroj
- Chomskyjeva hierarhija jezika

# Praktični sadržaji

- grep, regularni izrazi
- perl
- parseri
- seminari
- više prakse na FJJP2

# Primjena formalnih metoda

- izgradnja jezičnih procesora (compiler)
- izgradnja inteligentnih sustava
- protokoli za komunikaciju
- analiza prirodnog jezika (NLP)
- analiza prirodnog govora
- računalna lingvistika
- strojno prevodenje
- ....

# Formalni jezici i jezični procesori II

- Ljetni semestar
  - Izborni kolegij
  - Seminarski rad
  - Priprema za pisanje završnog rada
  - Završni rad
- Sadržaj
  - Leksička analiza
  - Sintaksna analiza
  - Semantička analiza
  - Jezični procesori / kompjajleri

# Računalna analiza prirodnog jezika (NLP)

- područje umjetne inteligencije (AI)
  - Turingov test
- upotrebljava
  - Konačni automati, Formalne gramatike
  - Chomskyeva hijerarhija jezika
  - Parseri
  - Statističke metode
- sroдna područja
  - Obrada govora (Speech Technologies): raspoznavanje, sinteza, dijalog
  - Računalna lingvistika (Computational Linguistics)

# Računalna lingvistika

- Jezične tehnologije (Language Technologies):
  - jezični resursi (korpusi, rječnici, leksikoni)
  - jezični alati (provjera gramatike i pravopisa)
  - obilježivači vrsta riječi (Part Of Speech Tagging)
  - morfološki analizatori (konačni automati)
  - prepoznavanje sintakse (parseri, gramatike)
  - prepoznavanje semantike (leksičkoga i rečeničnoga značenja)
  - prepoznavanje pragmatike (diskursa i dijaloga)
  - strojno prevodenje (strojno potpomognuto prevodenje)

# Inteligentna računala mogu:

- rješavati teške probleme
- pomoći pri istraživanjima i konstruiranjima
- pomoći u proizvodnji
- razumjeti prirodan jezik
- razumjeti slike
- naučiti određene primjere i uzorke
- ....

# Natural Language Processing-NLP

## Računalna analiza prirodnog jezika

- Računala na mogu razumjeti prirodni jezik poput male djece? Zašto je to tako teško?
  - nepravilnosti u jezicima
  - razumijevanje
  - dvosmiselnost
  - ....
- Računala ne mogu prevesti literalno djelo?
- Računala ne mogu stvoriti literalno djelo?



# NLP danas jedno od najživljih područja

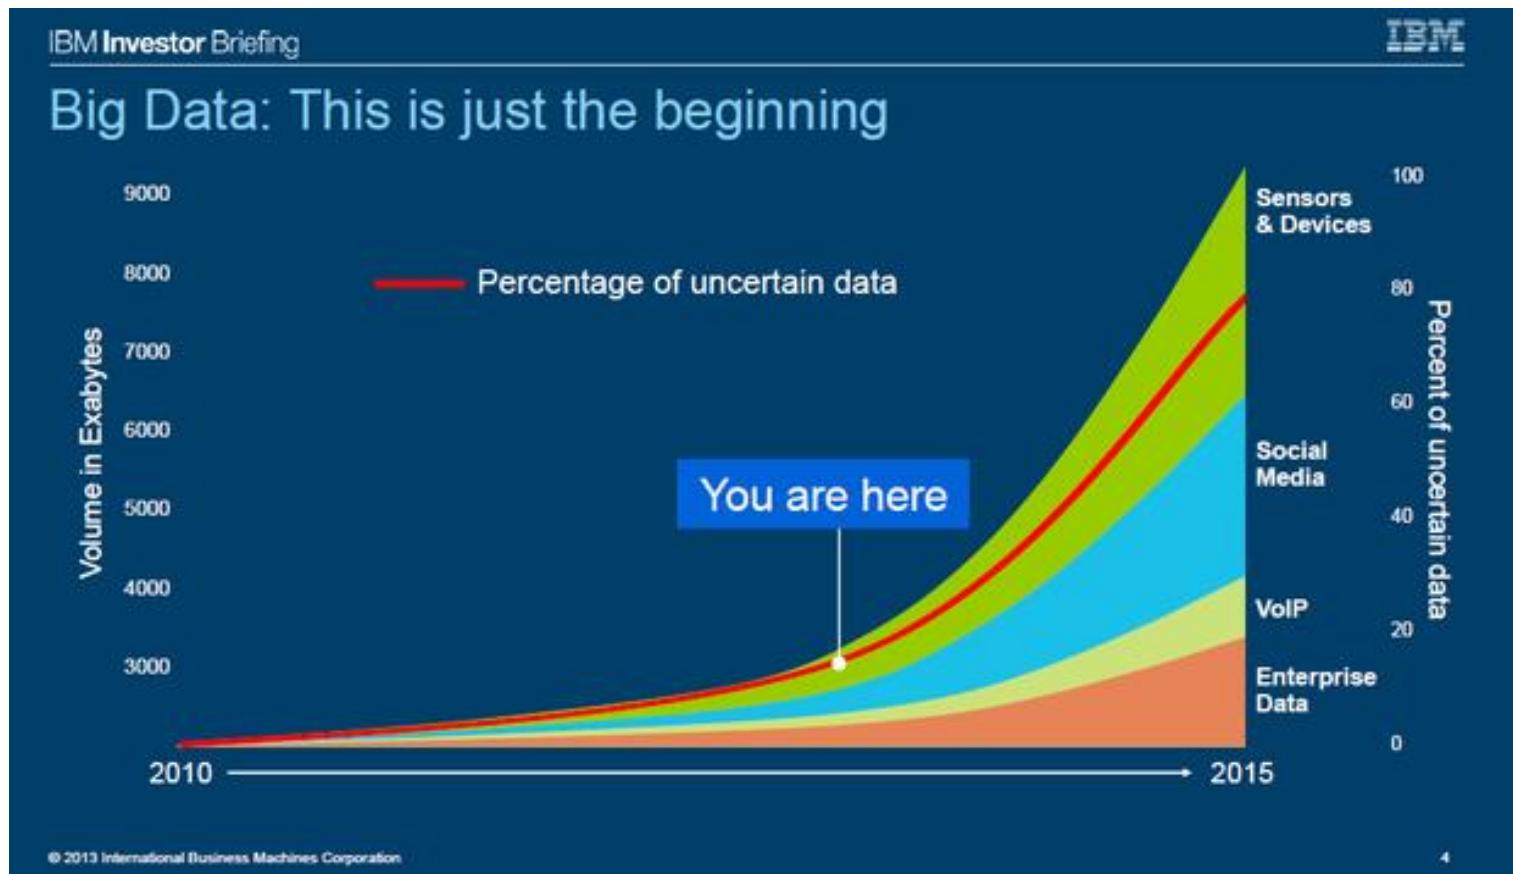
- analiza podataka velikog opsega (big data) podrazumijeva i rad s nestrukturiranim podacima – tekstovima, tweetovima, analizu mikroblogova, ...
- analiza stavova i mišljenja (sentiment analysis) – opet rad s tekstrom
- sustavi za preporuku (recomender systems) – analiza komentara – opet tekst
- ekstrakcija informacija, information retrieval, question answering, text mining,....
- strojno prevodenje,...
- sve navedeno su i moguće teme za seminar!!!!

# Usko vezano uz „Big data”

- <https://visual.ly/community/infographic/how/internet-real-time>



# Struktura podataka (IBM)



# Structured data

- data sources come in a **clear, predefined format**
- format is specified in details
- every piece of information is:
  - known ahead of time
  - has predefined format
  - occurs in a specified order
- this makes it easy to work with.
  - Example: RDBMS,

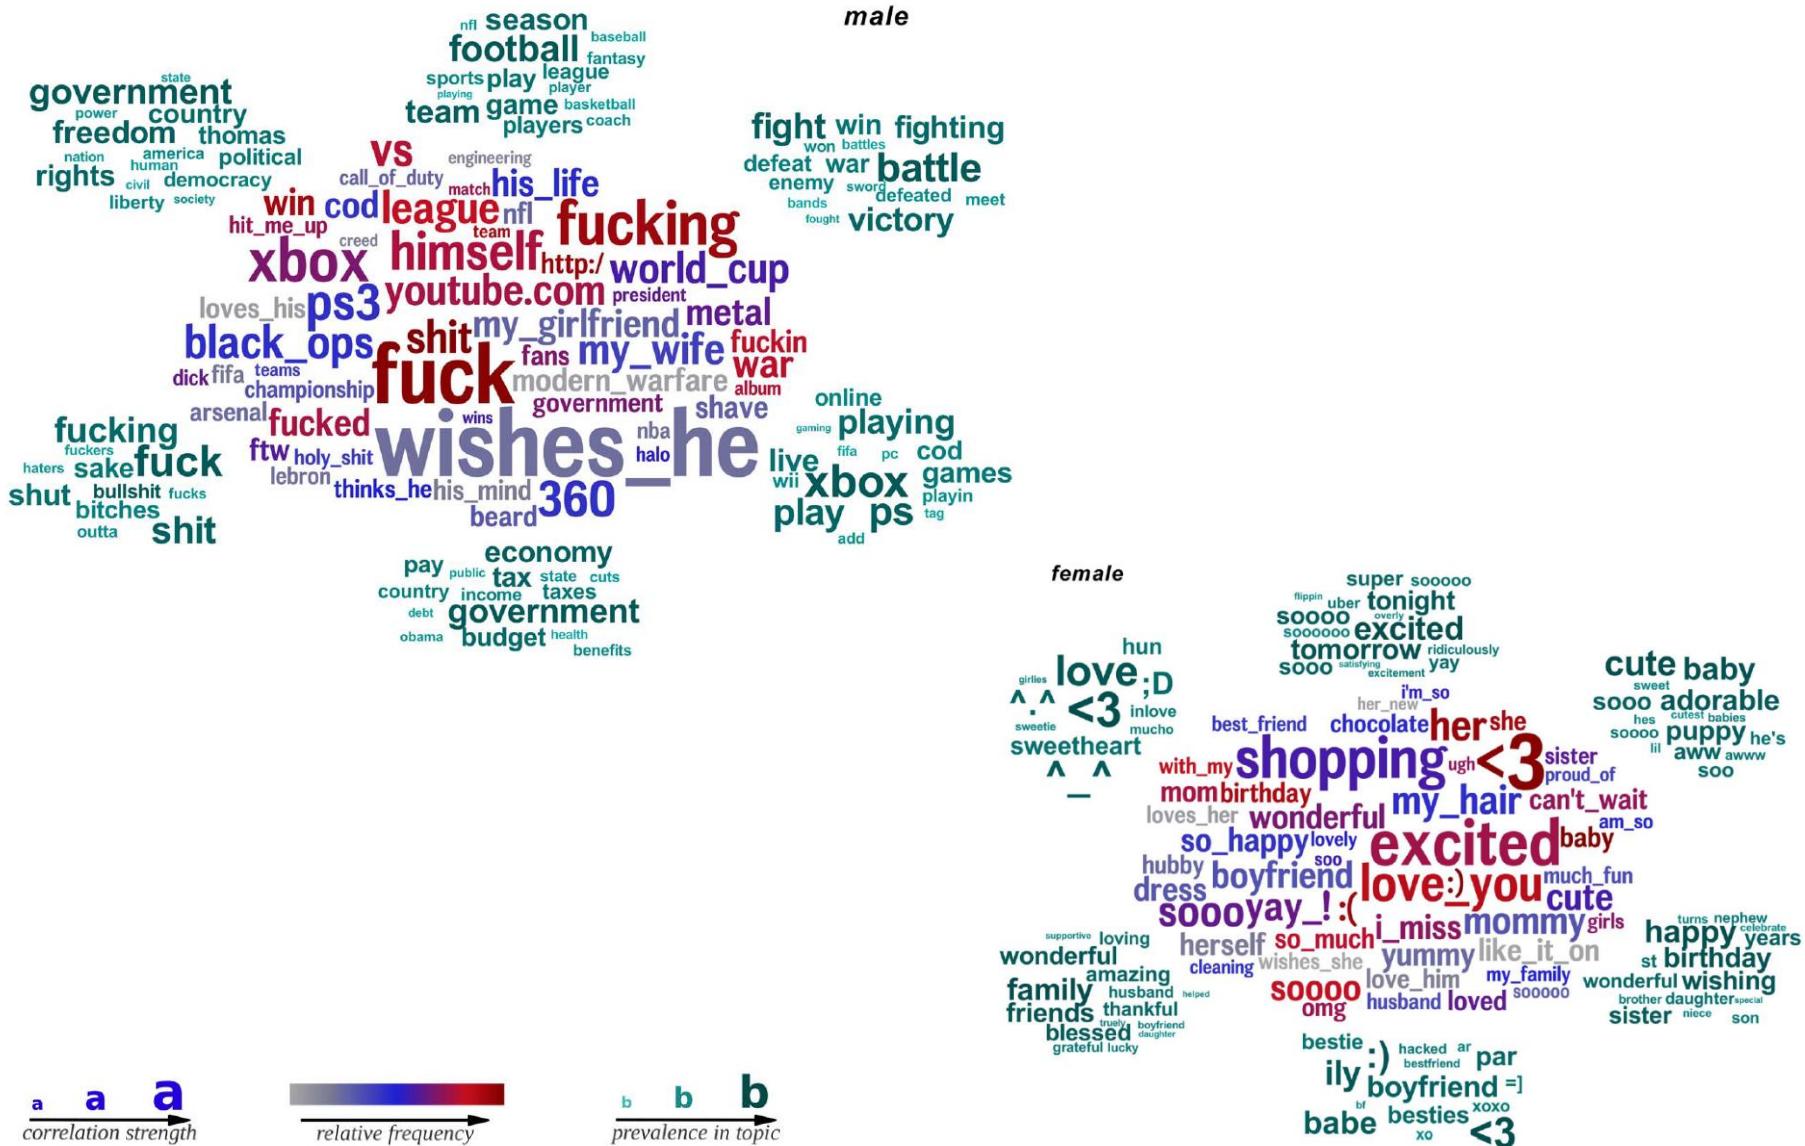
# Semi-structured data

- has a logical flow and format - but the format is not user-friendly
  - a lot of noise or unnecessary data intermixed with the nuggets of high value in such a feed
- for reading is necessary to employ complex rules
  - dynamically determine how to proceed after reading each piece of information
- can contain tags that separate semantic elements
  - which includes the capability to enforce hierarchies within the data
- Example: web logs, click streams, call center logs, ..

# Unstructured data

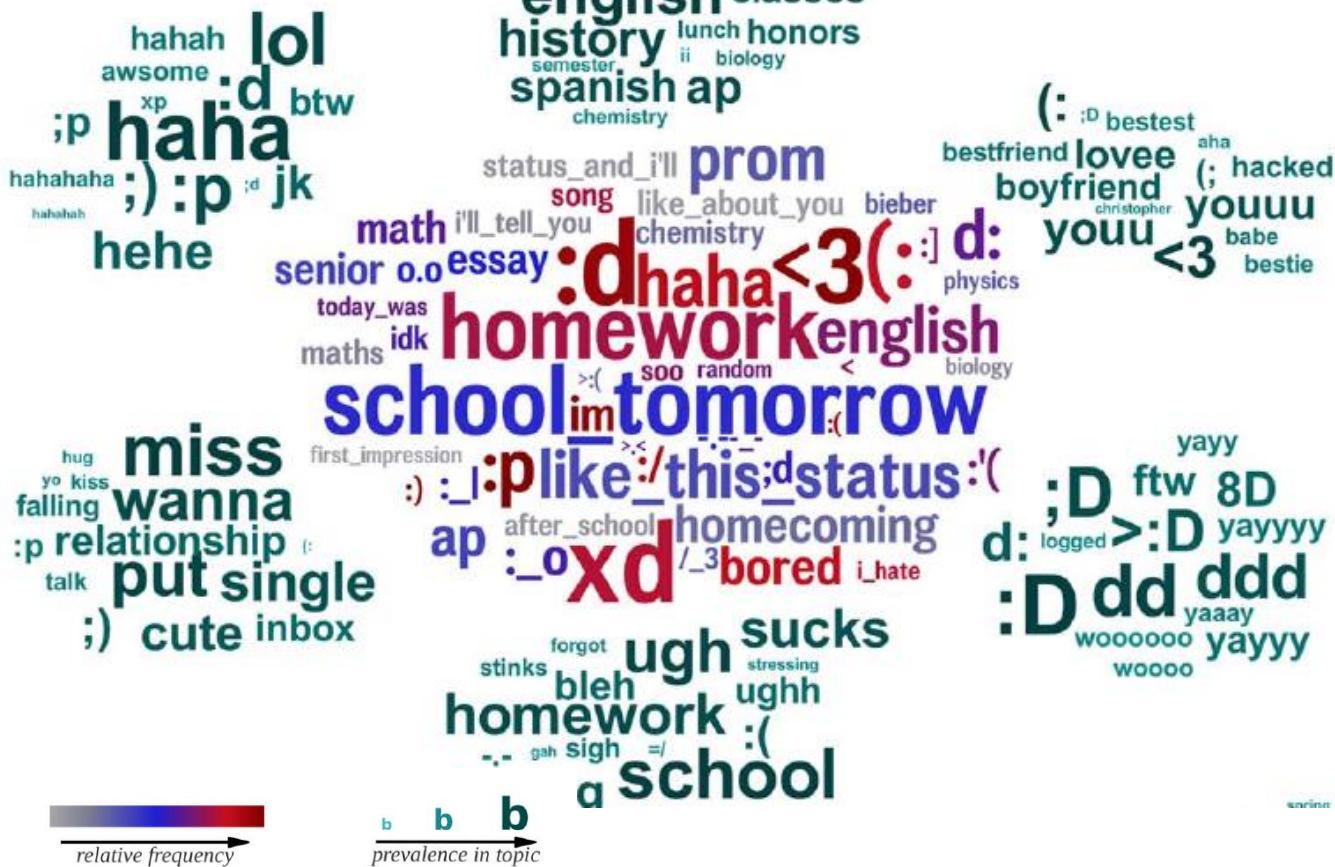
- is information that either does not have a predefined data model
  - and/or does not fit well into a relational database
- example: text, audio, video, image, geospatial and Internet data
- social networks

Schwartz HA, Eichstaedt JC, Kern ML, Dziurzynski L, Ramones SM, et al. (2013) Personality, Gender, and Age in the Language of Social Media: The Open-Vocabulary Approach. PLoS ONE 8(9): e73791. doi:10.1371/journal.pone.0073791



# skupina?

13-18



?

19-23



# Pregled po disciplinama

- Lingvistika – Computational Linguistics
- Računarstvo – Natural Language Processing
  - » Artificial Intelligence
- Elektrotehnika – Pattern Recognition,
  - » Speech Recognition
- Psihologija – Computational  
Psycholinguistics
- Affective Computing.....

# Znakovi i oznake

- skupovi
- abecede
- nizovi
- Booleova logika
- jezik
  - operacije nad jezicima
- grafovi
- stabla
- relacije

# Skupovi

- objekti skupa  $A=\{a_1, a_2, a_3, \dots, a_n\}$
- skup A je podskup skupa B:  $A \subseteq B$
- beskonačni skupovi  $A=\{a_1, a_2, a_3, \dots\}$
- prazni skup:  $\emptyset$
- unija skupova:  $A \cup B$
- presjek skupova:  $A \cap B$

# Skupovi

- kardinalni broj skupa je broj elemenata u konačnome skupu
  - ako između konačnih skupova postoji bijekcija imaju jednake kardinalne brojeve
  - ako je jedan podskup pravi podskup drugoga onda nemaju jednake kardinalne brojeve
  - prebrojivo beskonačni su skupovi za koje postoji bijekcija na skup prirodnih brojeva
  - neprebrojivo beskonačni skupovi – skup realnih brojeva
- unija:  $A \cup B = \{x \mid x \in A \vee x \in B\}$
- presjek:  $A \cap B = \{x \mid x \in A \wedge x \in B\}$

# Abeceda

- *Abeceda*: konačni skup znakova
- abeceda se sastoji od simbola
  - binarna abeceda
    - $B=\{0,1\}$ , nad brojkama 0 i 1
  - engleska abeceda
    - $\forall \Sigma_1=\{a,b,c,d,e,f,g,h,i,j,k,l,m,n,o,p,q,r,s,t,u,v,w,x,y,z\}$
  - hrvatska abeceda
    - $\forall \Sigma_2=\{a,b,c,\check{c},\acute{c},d,d\check{z},\check{d},e,f,g,h,i,j,k,l,lj,m,n,nj,o,p,q,r,s,\check{s},t,u,v,z,\check{z}\}$
  - abeceda  $\Gamma$ 
    - $\forall \Gamma=\{0,1, x,y,z\}$

# Niz

- je konačni slijed znakova abecede postavljen jedan do drugog
  - 011, 1011, 10110001 su nizovi nad abecedom  $B=\{0,1\}$
  - *duljina* niza: je broj znakova u nizu ( $w=101100$ ,  $|w|=6$ )
  - *prazan* niz: je niz dužine 0 i označava se  $\varepsilon$ ;  $|\varepsilon|=0$
  - *prefiks* niza  $w$ : dobije se odbacivanjem 0, 1 ili više posljednjih znakova niza  $w$
  - *sufiks* niza  $w$ : dobije se odbacivanjem 0, 1 ili više početnih znakova niza  $w$

# Niz II

- ***podniz*** niza  $w$ : dobije se odbacivanjem prefiks i sufiksa niza  $w$
- ***pravi*** podniz, prefiks ili sufiks niza  $w$ : je neprazan niz  $x$  koji je podniz, prefiks ili sufiks niza  $w$  i  $w \neq x$ .
- ***podsljed*** niza  $w$ : dobije se odbacivanjem niti jednog, jednog ili više ne uzastopnih znakova niza  $w$
- ***nadovezivanje (konkatenacija)*** nizova  $x$  i  $y$ : dobije se dodavanjem znakova niza  $y$  iza znakova niza  $x$ , bez razmaka;  $w=xy$
- ***palindrom***: niz znakova koji se s obje stane čita jednako: 0, 00, 010, 1101011, abcba

# Booleova logika

- Vrijednosti:
  - **TRUE** / točno / 1 i **FALSE** / netočno / 0
- AND / konjunkcija / I:  $A \wedge B$
- OR / disjunkcija / ILI:  $A \vee B$
- NOT / negacija / NE:  $\neg A$
- XOR/ ekskluzivno ILI:  $A \oplus B$
- IMPLIKACIJA                     $\Rightarrow / \rightarrow$
- EKVIVALENCIJA                 $\Leftrightarrow / \leftrightarrow$

# Jezik

- *Jezik* je skup nizova nad abecedom
  - npr.: prazan skup  $L_1 = \{ \}$  ili skup nizova koji imaju paran broj nula i jedinica  $L_2 = \{00, 11, 0011, 0101, 1010, 1001, \dots\}$   $L_2$  nije konačan skup
  - skup svih mogućih nizova nad nekom abecedom -  $\Sigma$ ; nije konačan i označava se sa  $\Sigma^*$
  - npr: jezik  $L_3 = \Sigma^* = \{\varepsilon, 0, 1, 01, 11, 00001, \dots\}$  je skup svih mogućih nizova znamenaka iz abecede  $B = \{0, 1\}$

# Operacije nad jezicima

- *Unija* jezika  $L$  i  $N$ :  $L \cup N = \{w \mid w \in L \vee w \in N\}$
- *Presjek* jezika  $L$  i  $N$ :  $L \cap N = \{w \mid w \in L \wedge w \in N\}$
- *Razlika* jezika  $L$  i  $N$ :  
$$L - N = L \setminus N = \{w \mid w \in L \wedge w \notin N\}$$
- *Nadovezivanje* jezika  $L$  i  $N$ :  
$$L N = \{xy \mid x \in L \wedge y \in N\}$$
- *Kartezijev produkt* :  $L \times N = \{(x,y) \mid x \in L \wedge y \in N\}$
- *Partitativni skup*:  
$$2^L = \text{skup svih podskupova jezika } L$$
- *Komplement* jezika  $L$ :  $L^C = \{w \mid w \notin L\}$

# Operacije nad jezicima

- *Kleenov operator  $L^*$ :*

$$L^* = \bigcup_{i=0}^{\infty} L^i = L^0 \cup L^1 \cup L^2 \cup \dots$$

- *Kleenov operator  $L^+$ :*

$$L^+ = \bigcup_{i=1}^{\infty} L^i$$

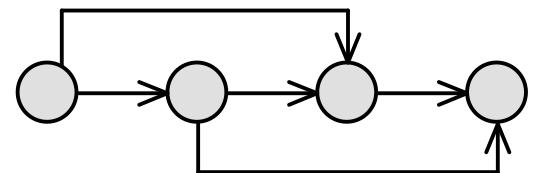
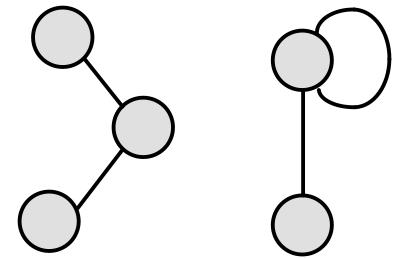
- nadovezivanje jezika samim sobom:  $L^2 = LL$
- definira se:

$$L^0 = \{ \epsilon \}$$

$$L^i = L^{i-1}L$$

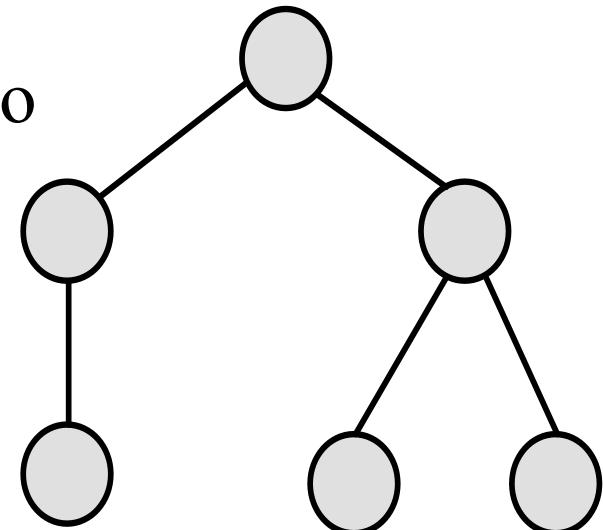
# Grafovi

- $G=(V, E)$ , gdje su
  - $V$ - čvorovi,  $E$  – parovi čvorova, grane
  - put grafa je niz čvorova  $v_1, v_2, \dots, v_k$ , ( $k \geq 1$ ), za koji vrijedi  $(v_i, v_{i+1})$  je grana grafa,  $\forall 1 \leq i \leq k$
  - duljina puta:  $k-1$
- Usmjereni graf:
  - grane usmjerenog grafa su uređeni parovi čvorova
    - usmjerene grane
  - neposredni prethodnik, neposredni sljedbenik



# Stablo

- je usmjereni graf za kojeg vrijedi:
  - čvor u korijenu nema prethodnika, i od njega vodi put do ostalih čvorova
  - svaki čvor, osim korijena ima točno jednog neposrednog prethodnika
  - roditelj – dijete
  - preci – potomci
  - korijen- unutrašnji čvor- list
  - stupanj: broj neposrednih nasljednika



# Relacije

- Binarna relacija je skup uređeni parova elemenata skupova  $(a,b) \in R$ :  $aRb$ 
  - element a je iz skupa domene, element b je iz skupa kodomene (domena i kodomena mogu biti isti skup S)
  - **refleksivnost**:  $\forall a \in S: aRa$
  - **nerefleksinost**: NE  $\exists a \in S: aRa$
  - **simetričnost**:  $\forall a \in S, \forall b \in S : aRb \Rightarrow bRa$
  - **asimetričnost**:  $\forall a \in S, \forall b \in S : aRb \Rightarrow \text{NE } bRa$
  - **tranzitivnost**:  $\forall a, b, c \in S: aRb \wedge bRc \Rightarrow aRc$
  - ekvivalencija: refleksivna + simetrična + tranzitivna relacija

# Okruženje relacije

- $\mathcal{P}$  je skup svojstava relacije R
- $\mathcal{P}$  – *okruženje* relacije R je najmanja relacija  $R'$  koja uključuje sve parova iz R i ima svojstva iz  $\mathcal{P}$
- **tranzitivno okruženje** relacije R:  $R^+$ 
  - ako je  $(a,b) \in R$  onda je  $(a,b) \in R^+$
  - ako je  $(a,b) \in R^+$  i ako je  $(b,c) \in R$  onda je  $(a,c) \in R^+$
  - niti jedan drugi element nije u  $R^+$
  - skup  $R^+$  uključuje skup R i ima svojstvo tranzitivnosti
- **refleksivno i tranzitivno okruženje** relacije R:
  - $R^* = R^+ \cup \{ (a,a) \mid a \in S \}$

# Formalni jezici i jezični procesori I

Prof. dr. sc. Sanda Martinčić - Ipšić  
[smarti@inf.uniri.hr](mailto:smarti@inf.uniri.hr)

# Formalni jezici i jezični procesori II

- Rad i izgradnja jezičnih procesora. Osnovne faze prevodenja programa.
- Analiza izvornog programa. Leksička analiza. Podatkovne strukture leksičke analize. Nejednoznačnosti i postupci oporavka kod pogreške. LEX i FLEX. Sintaksna analiza. Podatkovne strukture sintaksne analize. Sintaksna pravila. Parsiranje (od vrha prema dnu i od dna prema vrhu). YACC. Semantička analiza. Gradnja sintaksnog stabla. Prevodenje od vrha prema dnu. Rekurzivno prevodenje.
- Sinteza ciljnog programa. Dodjela memorije. Pristup nelokalnim imenima. Razmjena parametara. Generiranje međukoda. Generiranje ciljnog programa. Priprema izvođenja ciljnog programa. Optimiranje.

# Jezični procesori

- jezični procesor (compiler) prevodi zapis nekog programa iz izvornog jezika u ciljni jezik
- projektiranje jezičnih procesora koristi znanja iz područja programskih jezika, arhitektura računala, teorije jezika, algoritama, projektiranja programske opreme

# Zadatak JP

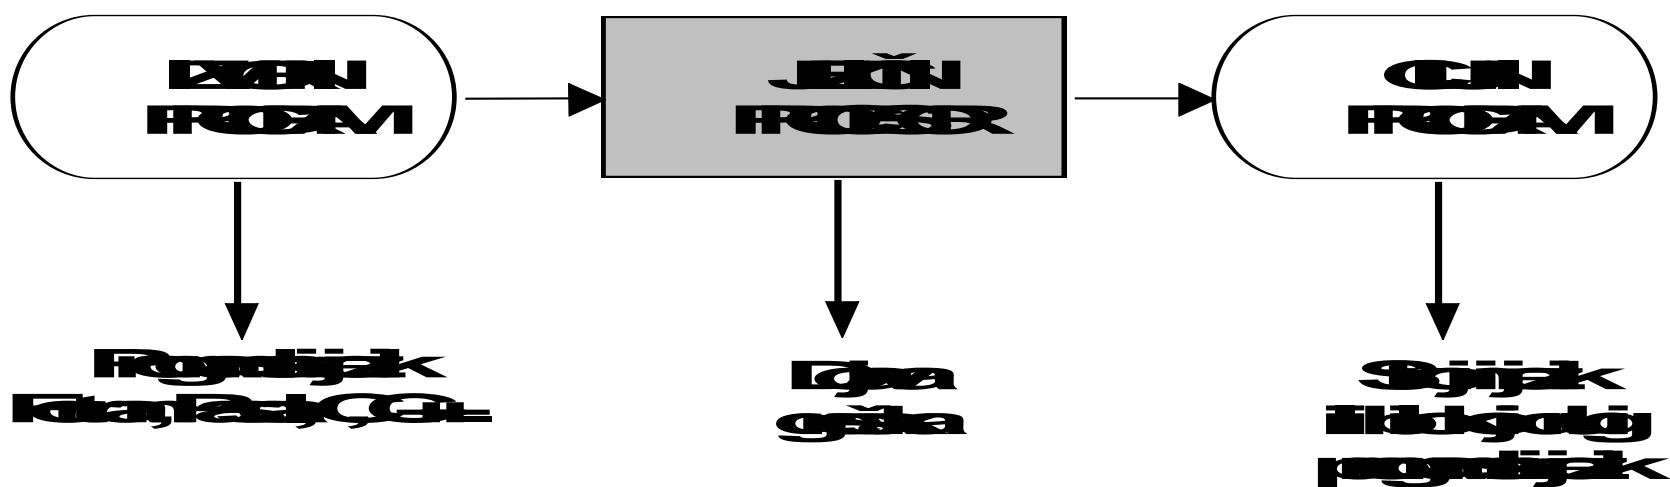
- zadatak jezičnog procesora je da svojim sučeljem približi računalo za uporabu na različitim područjima primjene
  - koristimo varijable, iterativne i rekurzivne algoritme, polja, datoteke, apstraktne tipove podataka..... a pri tome
  - ne treba poznavati sklopošku građu računala, registre, binarni zapis, numeričke adrese memorejske hijerarhije,...
  - oslobođiti jezik programiranja od arhitekture računala

# Zadatak JP II

- olakšati učenje viših programskih jezika
- olakšati razvoj i razumijevanje programa
- olakšati ispravljanje i pronalaženje pogrešaka
- olakšati održavanje i dokumentiranje
- povećati prenosivost programa između različitih računala (pa čak i na mobitele)
- skratiti vrijeme razvoja programa

# Jezični procesor (Compiler)

Def.: je program, koji neki program napisan u nekom određenom programskom jeziku, čita i prevodi u ekvivalentan program u nekom drugom jeziku.



# Jezični procesor II

- priprema korisničkog programa za izvođenje na računalu je složen višeslojni proces postupnog prevodenja korisničkog programa u izvediv strojni program
- većinom je prevodenje automatizirano
- strojne naredbe koje je moguće izvesti su uvijek nizovi nula i jedinica

# **Analiza izvornog programa**

## **1. Linerana analiza (leksička):**

- čitanje znakova izvornog programa s lijeva na desno i grupiraje znakova u simbole
- SIMBOL: niz znakova, koji zajedno imaju značenje

## **2. Hijerahjska analiza (sintaksna):**

- znakovi i simboli se udružuju u grupe, koje imaju neko određeno značenje

## **3. Semantička analiza:**

- provjerava smislenost dijelova programa

# Sinteza ciljnog programa

## 4. Generiranje međukoda:

- zapis izvornog programa u obliku koji se može izravno spremiti u memoriju računala

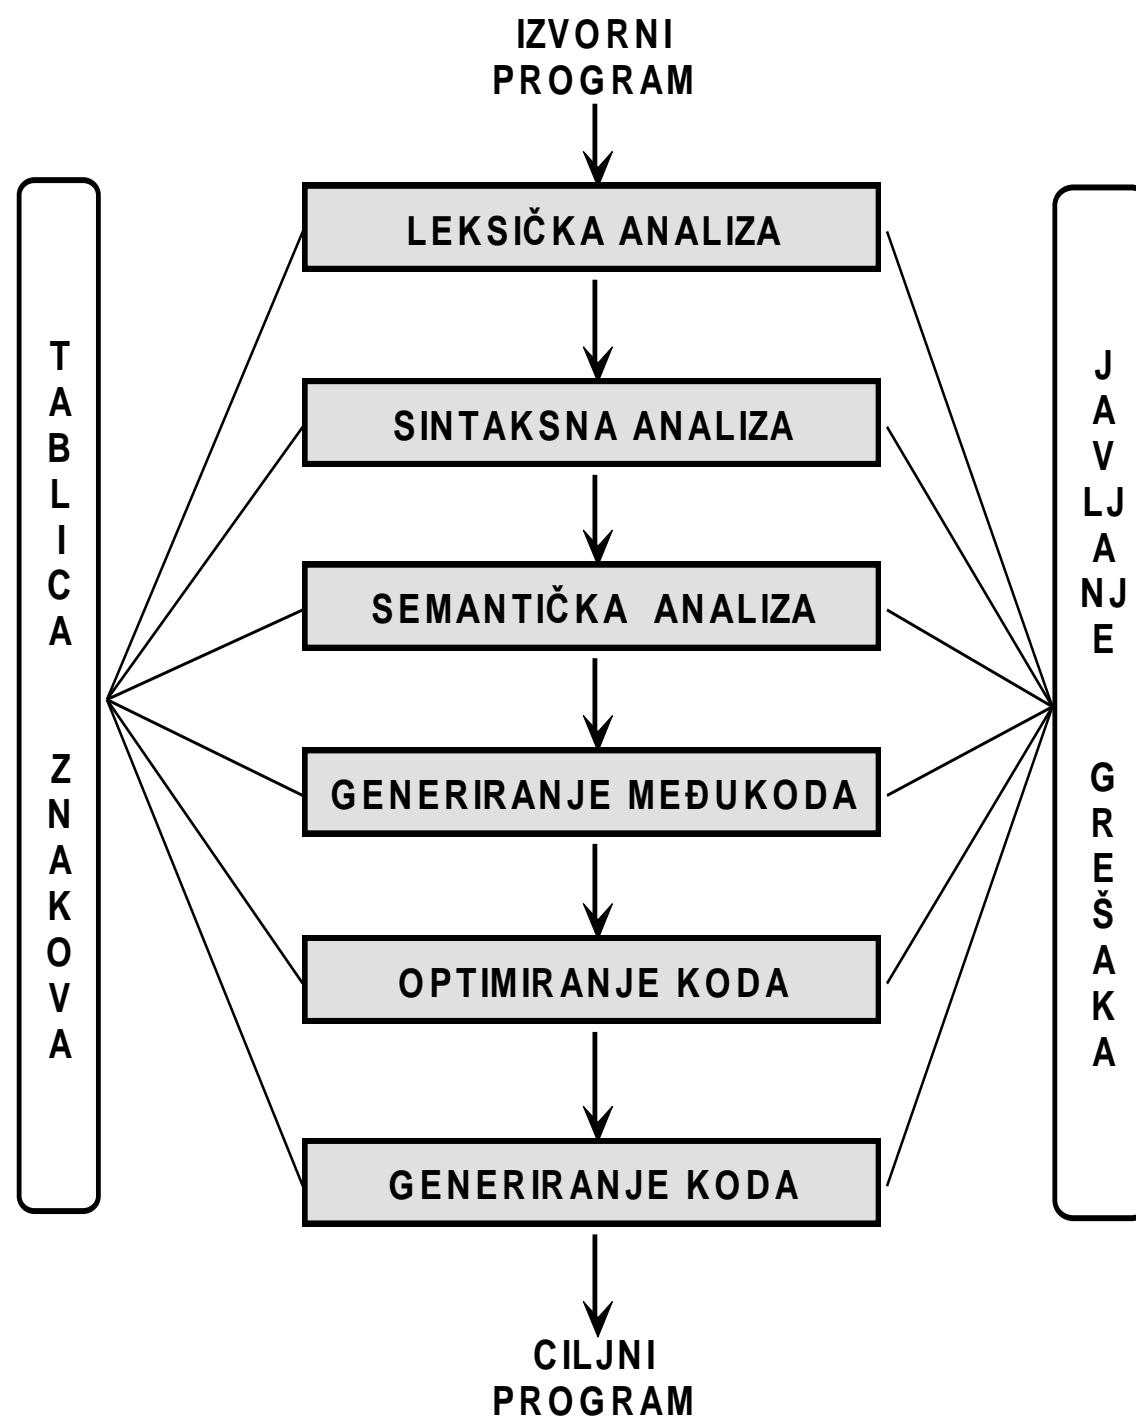
## 5. Optimiranje međukoda:

- poboljšanje kvalitete ciljnog programa: brzine izvođenja, veličine memorijskog prostora

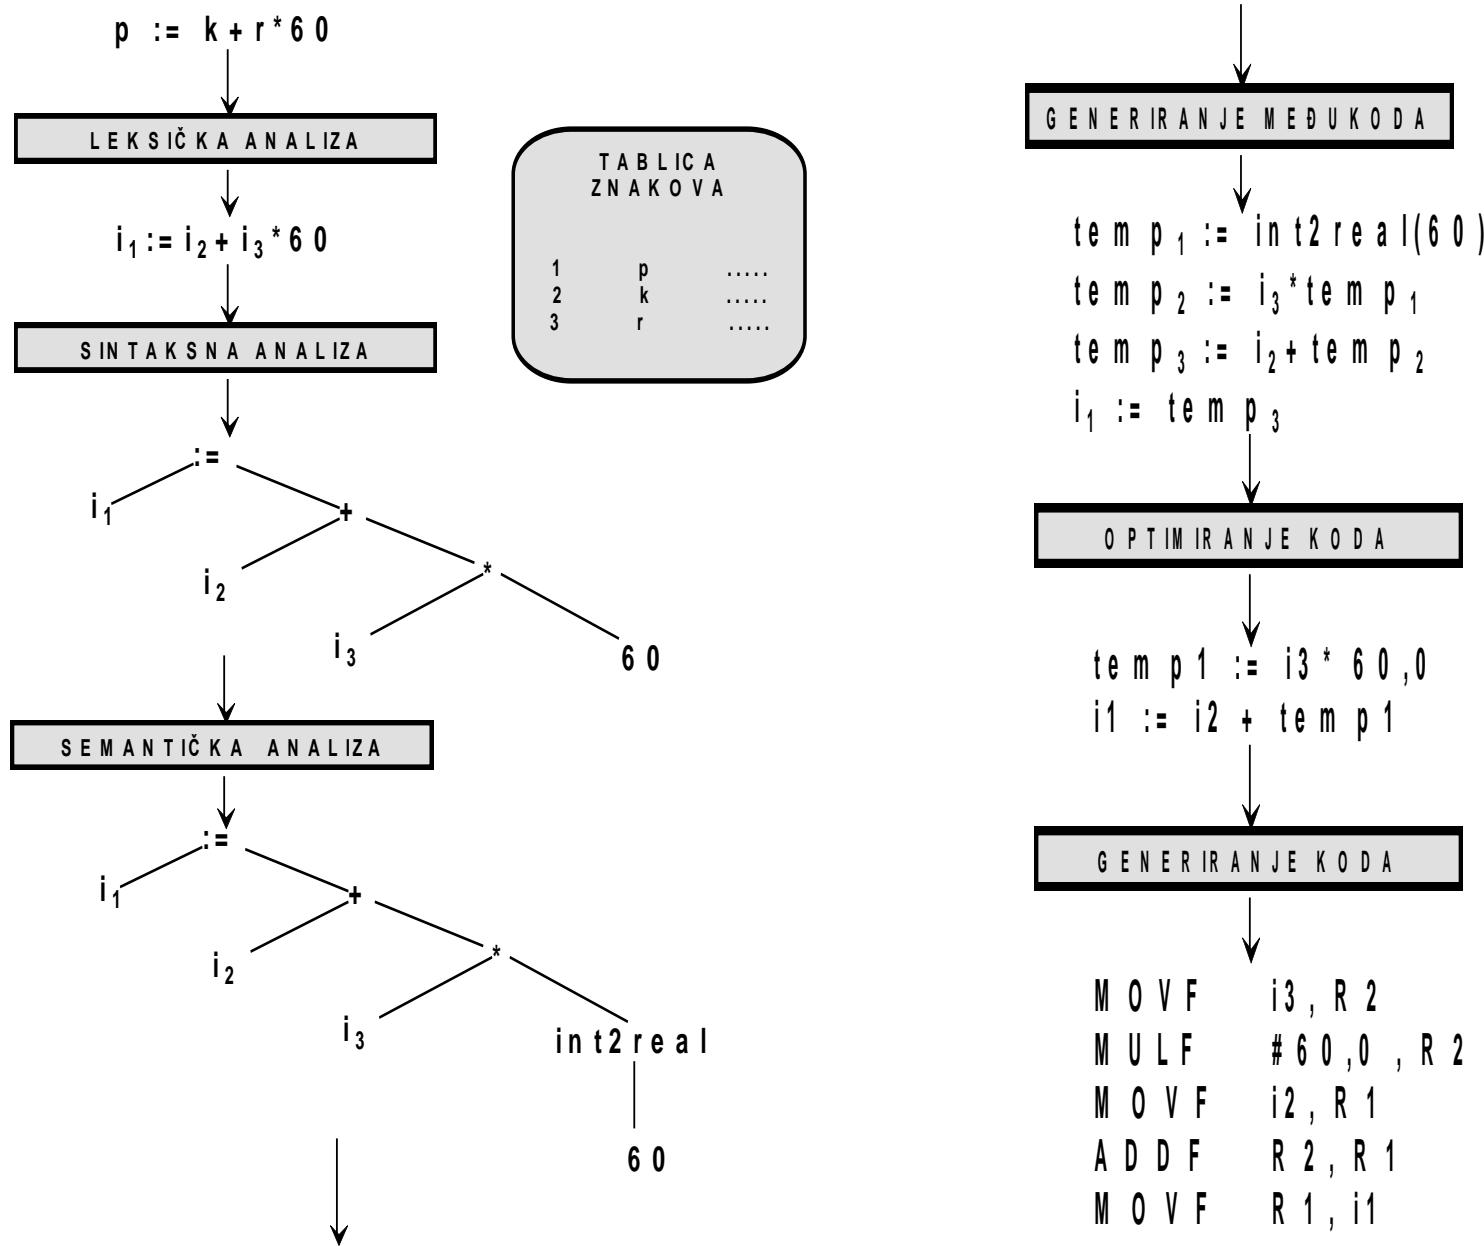
## 6. Generiranje koda:

- generiranje strojnog programa

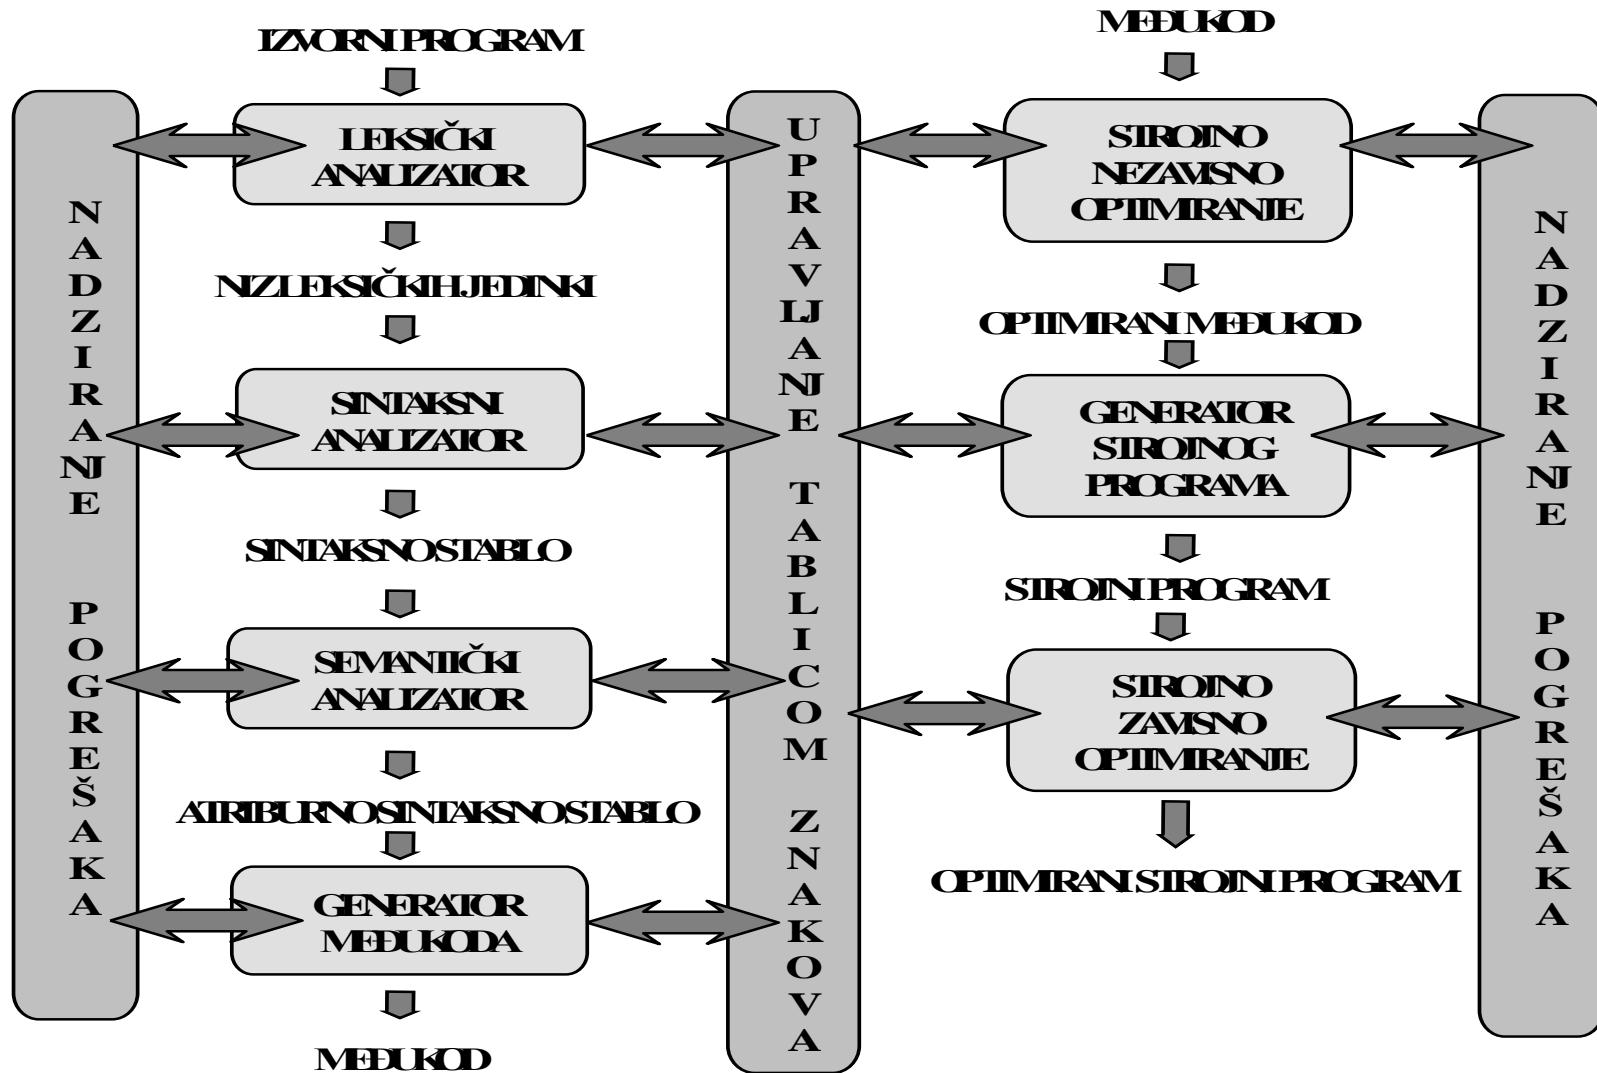
# Faze rada jezičnog procesora



# Primjer: rad jezičnog procesora



# Rad jezičnog procesora



# Prihvaćanje izvornog programa

- ispituje ispravnost izvornog programa pomoću **formalnih automata** s kojim se ispituje prihvaćanje nizova
  - čita se znak po znak izvornog programa

## Generiranje ciljnog programa

- ciljni program se generira pomoću **formalne gramatike**